

KLASIFIKASI SAWIT - ML

Nama Kelompok

Anggota :

- 1) 202210370311252 - Muhammad Wildan Nabila
[abilwildan2003@webmail.umm.ac.id - 082287944428]
- 2) 202210370311446 - Irawana Juwita
[irajuwita@webmail.umm.ac.id - 085749629122]
- 3) 202210370311363 - Diemas Andung Prayoga
[diemasandung@webmail.umm.ac.id - 085850652835]


1. Original Data

Data yang digunakan merupakan data gambar atau data citra yang akan dilakukan klasifikasi. Data merupakan data primer yang datanya telah diambil secara mandiri di perkebunan sawit selama kurang lebih satu minggu. Dataset memiliki sebanyak 3000 data gambar sawit yang terdiri dari 3 kelas yaitu mentah, matang, dan busuk, dengan jumlah data tiap kelas sebesar 1000 data.

2. EDA

2.1 Distribusi Jumlah per Kelas

Menampilkan berapa banyak data setiap kelasnya dengan visualisasi bar chart. Berikut visualisasinya:

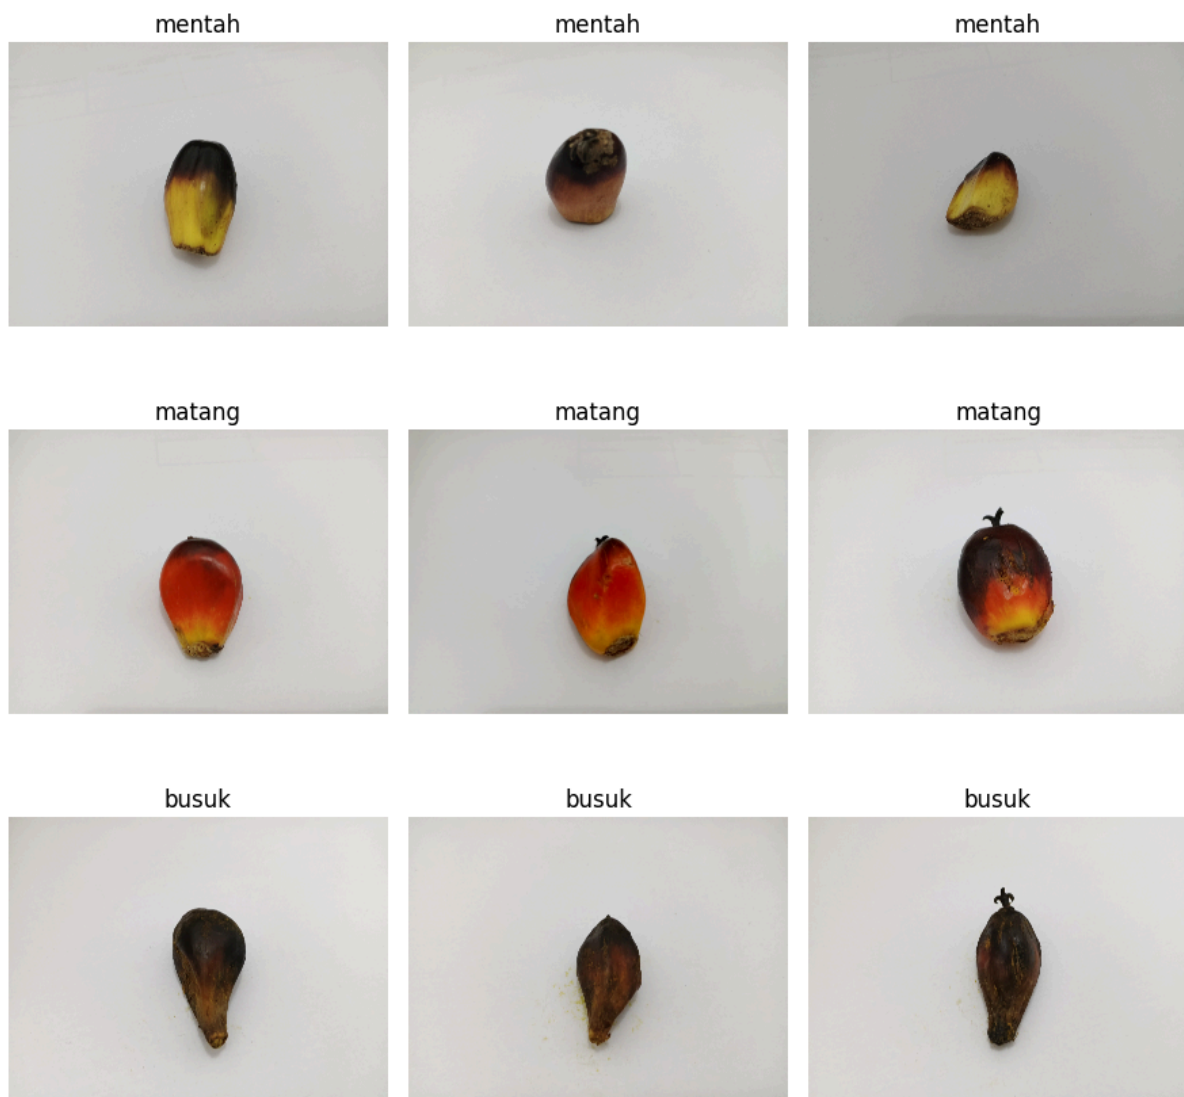


Gambar 1. Distribusi per Kelas

Gambar 1. di atas menunjukkan bahwa jumlah di antara kelas itu seimbang yaitu sebanyak 1000 data per kelas.

2.2 Grid Sampel Data per Kelas

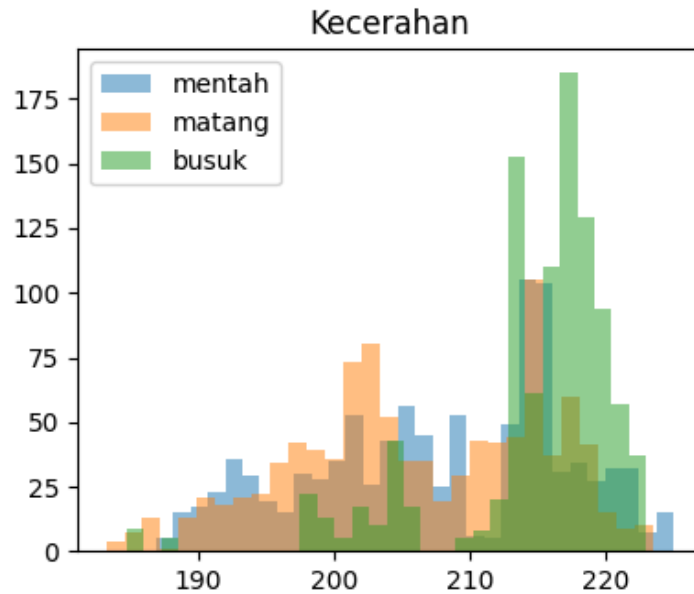
Menampilkan sampel data per kelas dilakukan untuk memastikan bahwa labelnya benar, latar konsisten, dan ciri diantara kelas memang berbeda. Berikut sampel datanya:



Gambar 2. Sampel Data per Kelas

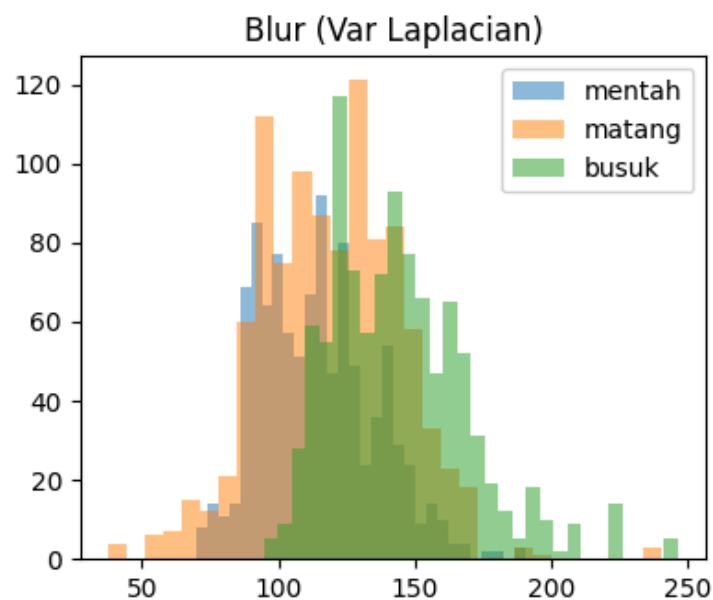
2.3 Kualitas Dasar (Resolusi, Exposure, dan Blur)

Kualitas dasar citra dibuat untuk mengetahui bahwa setiap citra dihitung ukurannya (lebar, tinggi, rasio), kecerahan global (rata-rata luminance sRGB), dan ketajaman (Variance of Laplacian), dan ukuran berkas. Berikut visualisasinya:



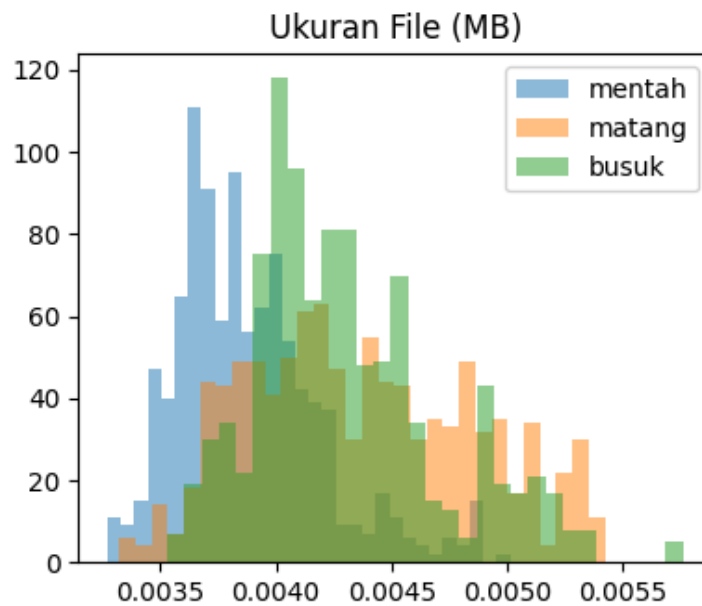
Gambar 3. Distribusi Kecerahan

Pada Gambar 3. di atas menunjukkan bahwa kecerahan global stabil dengan pergeseran kelas busuk cenderung ke kanan (lebih terang) daripada mentah dan matang. Terang yang dimaksud biasanya dipengaruhi oleh perbedaan proporsi latar dan objek atau kecerahan saat mengambil gambar.



Gambar 4. Distribusi Blur

Pada Gambar 4. di atas menunjukkan bahwa, jika sumbu X semakin ke kanan artinya citra makin tajam/lebih banyak tepi. Distribusi kelas busuk bergeser paling kanan karena permukaan yang bertekstur, matang berada di tengah, dan mentah cenderung kiri.

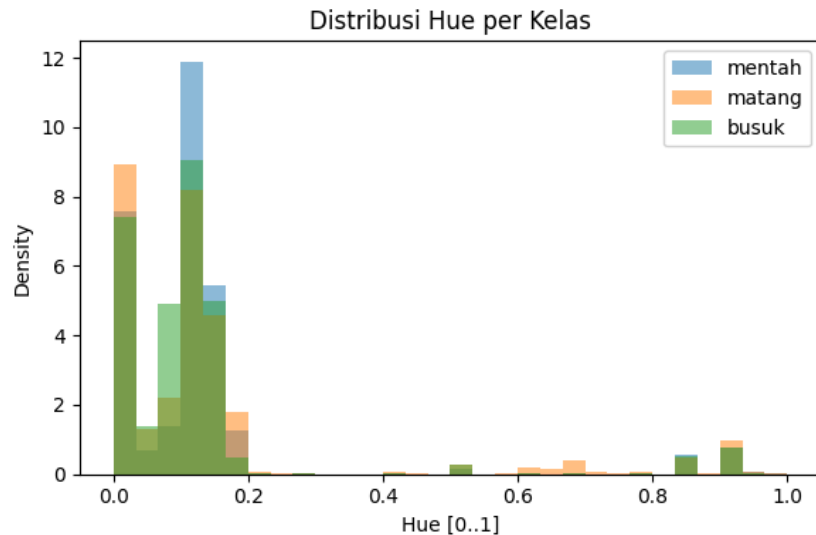


Gambar 5. Distribusi Ukuran Berkas tiap Kelas

Pada Gambar 5. di atas menunjukkan bahwa kompresi berhasil dan konsisten antar kelas. Setiap citra disimpan sebagai JPEG quality 90 yang berukuran 224x224 dengan letterbox. Ketiga kelas mengelompok rapat sekitar 0.0035 - 0.0055 MB atau sekitar 3.5 - 5.5 KB.


2.4 Analisis Warna (Hue Density dan Lab Scatter)

Analisis warna digunakan untuk memverifikasi bahwa perbedaan tingkat kematangan brondolan (mentah–matang–busuk) memang tercermin pada sinyal warna. Berikut 2 visualisasi yang saling melengkapi yaitu Hue menangkap “nada” warna dominan, sedangkan Lab Scatter lebih dekat dengan persepsi manusia dan stabil untuk analisis statistik.:



Gambar 6. Distribusi Hue

Gambar 6. di atas menunjukkan bahwa puncak terdapat pada sumbu X rentang 0.05 - 0.20 yaitu berwarna merah ke oranye (rentang 0.08 - 0.15), mentah sedikit lebih kuning (0.12–0.20), sedangkan busuk memiliki sebaran lebih lebar karena area cenderung gelap.



Gambar 7. Distribusi Lab Scatter

Gambar 7. di atas menunjukkan pemisahan warna antar kelas yang jelas: matang yaitu oranye-merah (a^* , b^* tinggi), mentah yaitu kuning ke hijau-kuning (a^* , b^* menengah), busuk yaitu kedekatan netral (a^* , b^* rendah). Hasil ini konsisten dengan Hue Density dan

menguatkan pemakaian fitur Lab moments (mean/STD a^* , b^*) serta rasio chromaticity sebagai prediktor.

2.5 Deteksi Duplikasi Citra

Memastikan tidak ada citra duplikat/near-duplikat yang dapat menimbulkan kebocoran data atau bias evaluasi. Hasil menunjukkan bahwa duplikasi nya adalah 0.

3. Preprocessing Data

3.1 Koreksi orientasi EXIF

Langkah ini diterapkan untuk mencegah gambar tampil menyamping/terbalik (khas kamera HP). Menggunakan penerapan `ImageOps.exif_transpose` untuk memastikan orientasi piksel sesuai realitas.

3.2 Pengecilan Resolusi (resize sisi terpanjang 1024 piksel)

Gambar asli dikecilkan proporsional hingga sisi terpanjang 1024 piksel (tanpa upscaling jika sudah lebih kecil). Langkah ini membuat I/O dan pelatihan lebih efisien tanpa menghilangkan informasi penting.

3.3 Normalisasi Warna

Langkah ini mengurangi variasi white-balance antar sesi pemotretan dan menstabilkan fitur warna untuk klasifikasi tingkat kematangan. Penerapan gray world color constancy diterapkan dengan penyesuaian skala kanal RGB sehingga rata-rata intensitas ketiga kanal seimbang mendekati warna abu-abu.

3.4 Letterbox Persegi dan Resize 224x224

Gambar ditempatkan pada kanvas persegi berwarna putih, lalu diubah ukurannya ke 224×224 piksel (standar input CNN) menggunakan interpolasi LANCZOS. Warna padding diset putih agar konsisten dengan latar dataset serta efisien dalam kompresi JPEG.

3.5 Penyimpanan Data

Hasil akhir disimpan sebagai JPEG dengan kualitas 90 (`quality=90`, `optimize=True`). Pada resolusi akhir 224×224, quality 90 menjaga tepi/tekstur tetap jelas (penting untuk fitur CNN), sementara ukuran file turun tajam sekitar 3 - 6 KB.

3.6 Verifikasi Visual (Before - After)

Perbandingan Sebelum vs Sesudah Preprocessing — mentah



Gambar 8. Hasil Preprocessing Kelas Mentah

Perbandingan Sebelum vs Sesudah Preprocessing — matang

matang — ORI
matang (1).jpg



matang — PRE
matang (1).jpg




matang — ORI
matang (8).jpg




matang — PRE
matang (8).jpg



matang — ORI
matang (80).jpg



matang — PRE
matang (80).jpg



Gambar 9. Hasil Preprocessing Kelas Matang

Perbandingan Sebelum vs Sesudah Preprocessing — busuk

busuk — ORI
busuk (1).jpg



busuk — PRE
busuk (1).jpg



busuk — ORI
busuk (139).jpg



busuk — PRE
busuk (139).jpg



busuk — ORI
busuk (8).jpg



busuk — PRE
busuk (8).jpg



Gambar 10. Hasil Preprocessing Kelas Busuk

4. KLASIFIKASI KLASIK

- **Model Klasifikasi Klasik yang digunakan**

Model yang digunakan untuk klasifikasi klasik sebagai berikut:

A. Extreme Gradient Boosting (XGBoost)

XGBoost adalah algoritma boosting berbasis ansambel pohon keputusan yang membangun pohon secara bertahap untuk memperbaiki kesalahan model sebelumnya. XGBoost meminimalkan loss dengan menambahkan regularisasi sehingga tidak overfitting. Dipilih karena akurat pada data tabular ataupun citra dengan ekstraksi fitur (warna, tekstur, Gabor, wavelet), mampu menangani kelas yang tidak seimbangan, dan serta menyediakan feature importance serta interpretasi via SHAP.

B. Support Vector Machine (SVM)

SVM mencari hyperplane dengan margin maksimum untuk memisahkan kelas. SVM dapat membentuk batas keputusan non-linear di ruang fitur. Dipilih karena mampu melakukan pemisahan kelas pada representasi fitur terstandarisasi, sering unggul pada fitur tekstur, serta efektif ketika jumlah fitur moderat.

C. Extremely Randomized Trees (ExtraTrees)

ExtraTrees mirip seperti Random Forest, beda pada titik pemisahan yang dipilih lebih acak pada setiap pilihan fitur. Ini membuat pelatihan lebih cepat dan menurunkan variansi model. Dipilih karena sangat cepat, tahan overfitting, cocok sebagai pembanding/alternatif RF pada fitur klasik citra, dan tetap menyediakan feature importance untuk interpretasi.

- **Eksperimen**

A. Splitting Data

Pembagian jumlah data sebagai berikut:

1. Data Train

Digunakan untuk melatih model. Data yang digunakan sebesar 70% dari 1000 data tiap kelasnya, sehingga data train tiap kelas yaitu 700

data. Dikarenakan terdapat 3 kelas maka total keseluruhan data train yang dipakai adalah 2100 data.

2. Data Validasi

Data validasi digunakan untuk tuning parameter dan cek overfitting. Data yang digunakan sebesar 15% yaitu terdapat 150 data tiap kelasnya, dengan total keseluruhan 3 kelas menjadi 450 data.

3. Data Test

Data validasi digunakan untuk evaluasi di akhir. Data yang digunakan sebesar 15% yaitu terdapat 150 data tiap kelasnya, dengan total keseluruhan 3 kelas menjadi 450 data.

B. Ekstraksi Fitur

1. Fitur Warna

Fitur warna merepresentasikan distribusi dan komposisi warna citra untuk membedakan kelas. Pada proyek ini, warna sawit sangat informatif karena tingkat kematangan sawit berkorelasi dengan perubahan rona (HUE), berikut warnanya:

- a. Mentah: Kuning–kehijauan
- b. Matang: Oranye–kemerahan
- c. Busuk: Coklat–kehitaman

Fitur yang di ekstrak:

- a. Konversi ruang warna
 - RGB: Kanal dasar
 - HSV: Persepsi manusia yaitu Hue, Saturation, dan Value
- b. Statistik global RGB (6 fitur)
 - Mean (R, G, B): 3 fitur
 - Std (R, G, B): 3 fitur
- c. Statistik global HSV(6 fitur)
 - Mean (H, S, V): 3 fitur
 - Std (H, S, V): 3 fitur
- d. Histogram Hue (16 fitur)

Digunakan untuk menangkap distribusi rona (proporsi warna).

e. Total fitur

$$6 \text{ (RGB)} + 6 \text{ (HSV)} + 16 \text{ (Hue)} = 28 \text{ fitur tiap citra}$$

2. Fitur Tekstur (LBP + GLCM)

Fitur tekstur mengekstrak pola permukaan buah sawit yang tidak tertangkap oleh warna, seperti kekasaran, kerutan, atau serat kulit. Fitur tekstur ini menggunakan 2 macam ekstraksi yaitu Local Binary Pattern (LBP) dan Gray Level Co-occurrence Matrix (GLCM) dimana keduanya saling melengkapi. LBP menangkap pola mikro-tekstur lokal (tepihan halus/kasar, pori, kerutan) dan GLCM merangkum hubungan piksel yang ada (kontras, homogenitas, energi, korelasi). Berikut tahapan ekstraksi yang dilakukan dalam fitur tekstur:

a. Praproses

Dilakukan konversi citra ke grayscale.

b. LBP

Menggunakan parameter: $P=8$ (tetangga), $R=1$ (rasio), $\text{method}=\text{uniform}$

c. GLCM

- $\text{distances}=[1,2,3]$, $\text{angles}=[0, \pi/4, \pi/2, 3\pi/4]$, $\text{levels}=256$, $\text{symmetric}=\text{True}$, $\text{normed}=\text{True}$.
- Properti diekstrak & dirata-rata lintas jarak berupa, contrast, dissimilarity, homogeneity, ASM, energy, correlation.

d. Vektor Fitur Akhir

Gabung: $10 \text{ (LBP)} + 6 \text{ (GLCM)} = 16 \text{ dimensi}$.

LBP dapat sensitif terhadap noise dan pilihan parameter (P , R), sedangkan GLCM sensitif ke kuantisasi grayscale, ukuran jendela, dan jarak yang dipilih.

3. Fitur Gabor

Fitur gabor dapat menangkap pola tekstur yang berorientasi (arah serat/kerutan) dan berfrekuensi tertentu yang relevan untuk membedakan permukaan sawit mentah–matang–busuk yang

menunjukkan perbedaan pola serat/kerutan pada skala tertentu. Berikut tahapan ekstraksi yang dilakukan dalam fitur gabor:

a. Praproses

Dilakukan konversi citra ke grayscale.

b. Bank Filter Gabor

- Orientasi : $[0, \pi/4, \pi/2, 3\pi/4]$ (4 arah).
- Frekuensi (freqs): $[0.1, 0.2, 0.3]$ (3 skala).
- Total kombinasi: $4 \times 3 = 12$.

c. Ekstraksi tiap kombinasi

- Magnitudo: $\text{mag} = \text{sqrt}(\text{real}^2 + \text{imag}^2)$.
- Statistik: Mean dan std dari mag.
- Fitur total per citra: $12 \times 2 = 24$ dimensi.

Kelebihan fitur gabor adalah tangkap arah & skala tekstur, fitur ringkas (24-dim) sangat baik. Sedangkan kekurangannya adalah sensitif ke blur & rotasi di luar sudut yang didefinisikan.

C. Evaluasi

1. Classification Report

Classification Report berupa ringkasan metrik performa untuk model klasifikasi. Laporan ini menunjukkan bagaimana performa model dalam memprediksi tiap kelas, menggunakan metrik-metrik utama dengan classification report berikut:

Tabel 1. Hasil Evaluasi Model Klasik

Model	Kelas	Acc	Precision	Recall	F1-Score
Tanpa Ekstraksi Fitur					
XGBoost	Mentah	0.98	0.99	0.99	0.99
	Matang		0.97	0.98	0.98
	Busuk		0.99	0.98	0.98
SVM	Mentah	0.96	0.97	0.97	0.97
	Matang		0.93	0.95	0.94

	Busuk		0.97	0.95	0.96
ExtraTrees	Mentah	0.98	0.98	0.99	0.98
	Matang		0.97	0.97	0.97
	Busuk		0.97	0.97	0.97
Ekstraksi Fitur					
XGBoost + Warna	Mentah	0.97	0.98	0.98	0.98
	Matang		0.95	0.97	0.96
	Busuk		0.98	0.97	0.97
SVM + Warna	Mentah	0.95	0.96	0.97	0.96
	Matang		0.92	0.94	0.93
	Busuk		0.97	0.94	0.95
ExtraTrees + Warna	Mentah	0.96	0.97	0.97	0.97
	Matang		0.94	0.96	0.95
	Busuk		0.98	0.96	0.97
XGBoost + Tekstur	Mentah	0.96	0.96	0.97	0.96
	Matang		0.93	0.95	0.94
	Busuk		0.97	0.95	0.96
SVM + Tekstur	Mentah	0.93	0.94	0.95	0.94
	Matang		0.90	0.93	0.91
	Busuk		0.97	0.93	0.95
ExtraTrees + Tekstur	Mentah	0.94	0.95	0.95	0.95
	Matang		0.91	0.94	0.92
	Busuk		0.97	0.93	0.95
XGBoost + Gabor	Mentah	0.95	0.95	0.96	0.96
	Matang		0.92	0.95	0.93
	Busuk		0.97	0.93	0.95
	Mentah		0.93	0.94	0.93

SVM + Gabor	Matang	0.92	0.88	0.92	0.90
	Busuk		0.96	0.91	0.93
ExtraTrees + Gabor	Mentah	0.93	0.93	0.95	0.94
	Matang		0.89	0.91	0.91
	Busuk		0.96	0.93	0.94

Analisis hasil klasifikasi report di atas sebagai berikut:

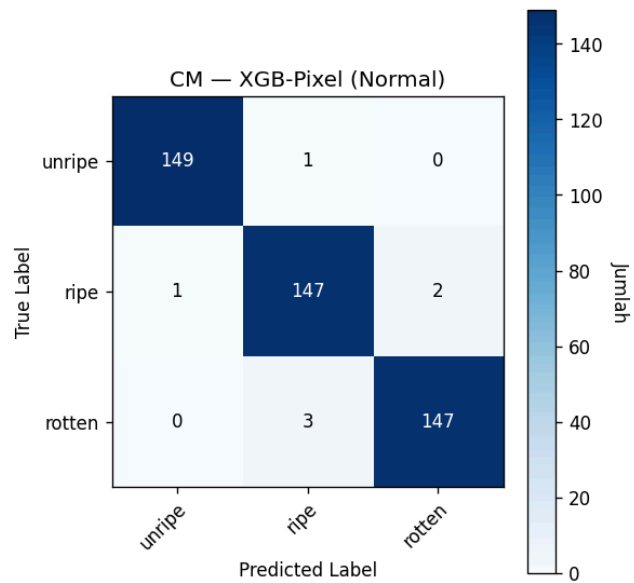
- a. Model klasik sudah mampu memberikan performa tinggi untuk klasifikasi kematangan sawit, dengan akurasi di atas 0,90 pada semua konfigurasi.
- b. XGBoost adalah algoritma paling konsisten dan paling unggul, terutama pada fitur Normal dan Warna.
- c. Walaupun kombinasi XGBoost + Normal memberikan akurasi tertinggi secara numerik (0,98), dalam penelitian ini XGBoost dengan fitur Warna dipilih sebagai best classical model karena:
 - Mengandalkan informasi warna yang lebih sederhana dan mudah dijelaskan secara domain agronomi,
 - Tetap menghasilkan akurasi dan F1-score yang sangat tinggi (~0,97) dan seimbang untuk ketiga kelas.

2. Confusion Matrix

Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, dibandingkan dengan label sebenarnya.

1) XGBoost

Analisis kinerja model XGBoost dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



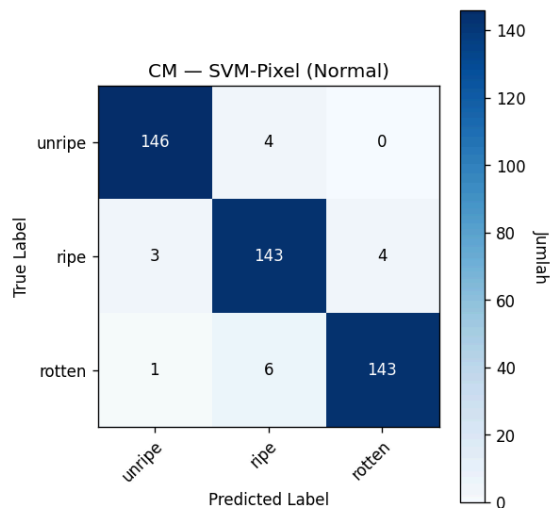
Gambar 11. Confusion Matrix XGBoost

Hasil Analisis:

- Total salah cuma 7 dari 450 sampel.
- Semua kelas punya recall sangat tinggi (149/150, 147/150, 147/150).
- Pola salah klasifikasi dominan antara matang dan busuk, tidak ada kelas busuk yang diprediksi mentah.
- Artinya, XGBoost sangat baik membedakan buah mentah dan matang, dan kadang masih bingung membedakan matang dengan busuk yang secara visual warna permukaannya mirip.

2) SVM

Analisis kinerja model SVM dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



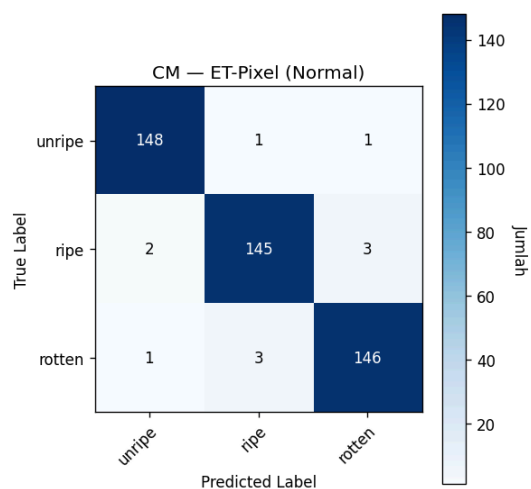
Gambar 12. Confusion Matrix SVM

Hasil Analisis:

- Total salah 18 dari 450 sampel lebih banyak dari XGB.
- Pada kelas mentah cukup baik, tapi masih ada 4 buah mentah yang dianggap matang.
- Kelas matang paling rentan salah prediksi.
- SVM masih perform dengan baik, tetapi lebih sering bingung pada kelas matang dan busuk, sehingga pola errornya lebih menyebar dibanding XGBoost.

3) ExtraTrees

Analisis kinerja model ExtraTrees dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



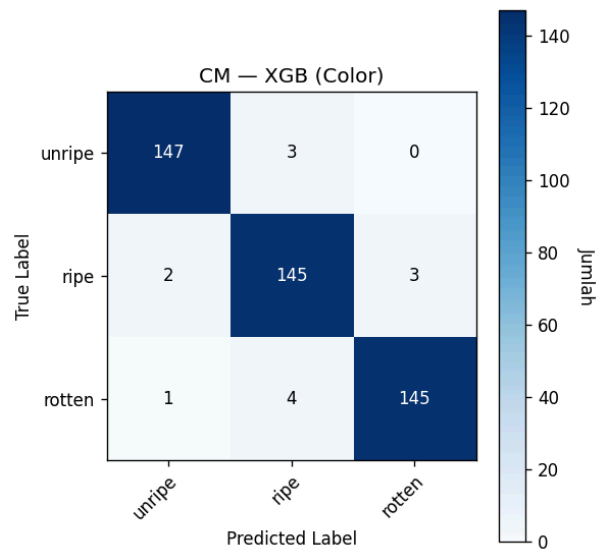
Gambar 13. Confusion Matrix ExtraTrees

Hasil Analisis:

- Total salah 11 dari 450 sampel
- Pada kelas mentah hampir sempurna (148/150), menunjukkan model mudah mengenali buah mentah.
- Extra Trees memberikan kinerja yang sangat baik dan stabil, namun sedikit kalah dari XGBoost dalam jumlah kesalahan dan ketajaman pemisahan antar kelas.

4) XGBoost + Warna

Analisis kinerja model XGBoost menggunakan fitur Warna dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



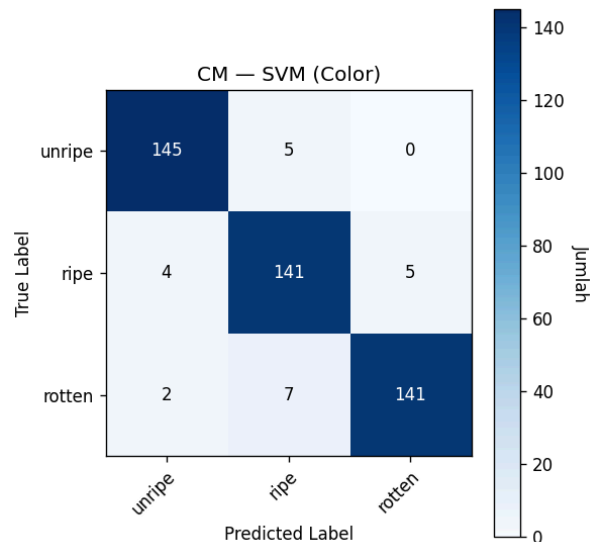
Gambar 14. Confusion Matrix XGBoost + Warna

Hasil Analisis:

- Total sampel salah prediksi hanya 13 sampel.
- Tidak ada kelas mentah ke busuk, dan tidak ada busuk ke mentah secara langsung. Kesalahan paling banyak terjadi pada mentah ke matang dan matang ke busuk.
- Artinya, model sangat baik memisahkan tiga kelas, namun tetap sedikit bingung di kelas transisi (matang) yang memang berada di tengah spektrum kematangan.

5) SVM + Warna

Analisis kinerja model SVM menggunakan fitur Warna dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 15. Confusion Matrix SVM + Warna

Hasil Analisis:

- Total sampel salah prediksi terdapat 23 sampel.
- Pola salahnya mirip XGB, tapi jumlah error lebih besar, terutama matang yang bergeser ke mentah atau busuk, dan busuk yang cukup sering diprediksi sebagai matang.
- SVM menunjukkan lebih sensitif terhadap variasi warna dan mungkin kurang fleksibel dalam memodelkan batas keputusan non-linear dibanding XGBoost.

6) ExtraTrees + Warna

Analisis kinerja model ExtraTrees menggunakan fitur Warna dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



Gambar 16. Confusion Matrix ExtraTrees + Warna

Hasil Analisis:

- Total sampel salah prediksi terdapat 16 sampel.
- Pola error hampir sama dengan XGB yaitu tidak ada mentah yang langsung jadi busuk, sebagian besar error lagi pada kelas matang ke mentah atau busuk dan busuk ke mentah.
- Secara performa, ET berada di tengah:
 - Lebih baik dari SVM (error lebih sedikit),
 - Sedikit di bawah XGB (error lebih banyak daripada XGB).

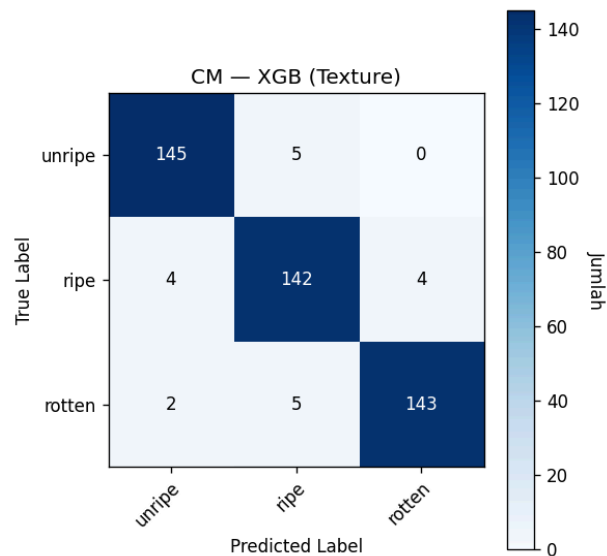
Analisis Fitur Warna:

Pada fitur Color, ketiga model klasik mampu menghasilkan confusion matrix yang didominasi oleh prediksi benar di sepanjang diagonal. Namun, XGBoost dengan fitur Color menunjukkan performa terbaik dengan total kesalahan paling sedikit dan pola mis-klasifikasi yang paling terkontrol, sehingga dipilih sebagai best classical model yang mewakili pendekatan berbasis fitur warna,

7) XGBoost + Tekstur

Analisis kinerja model XGBoost menggunakan fitur Tekstur dilakukan melalui confusion matrix yang merepresentasikan

jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 17. Confusion Matrix XGBoost + Tekstur

Hasil Analisis:

- Total sampel salah prediksi adalah 20 sampel
- Pola salah utama yang terjadi adalah prediksi mentah ke matang, matang ke mentah atau busuk, dan busuk ke matang.
- Sama seperti fitur Color, kelas matang menjadi kelas yang paling sering tertukar, mencerminkan bahwa pola tekstur buah matang berada di tengah antara unripe dan rotten.

8) SVM + Tekstur

Analisis kinerja model SVM menggunakan fitur Tekstur dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



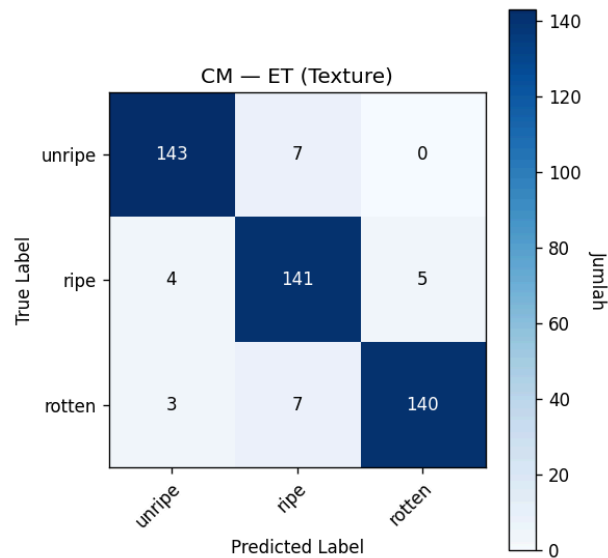
Gambar 18. Confusion Matrix SVM + Tekstur

Hasil Analisis:

- Total sampel salah prediksi lumayan besar yaitu 30 sampel
- Kelas matang dan busuk paling sering tertukar yaitu, busuk ke matang terdapat 8 kasus, dan juga matang ke mentah atau busuk terdapat 11 kasus salah prediksi.
- Hal ini menunjukkan bahwa SVM kurang fleksibel menangkap batas keputusan non-linear hanya dari informasi tekstur, sehingga mudah bingung pada pola permukaan yang mirip.

9) ExtraTrees + Tekstur

Analisis kinerja model ExtraTrees menggunakan fitur Tekstur dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



Gambar 19. Confusion Matrix ExtraTrees + Tekstur

Hasil Analisis:

- Total sampel salah prediksi lumayan besar yaitu 26 sampel.
- Pola error mirip XGB, tapi jumlah salahnya lebih banyak, terutama: mentah ke matang (7 kasus) dan busuk ke matang (7 kasus).
- Artinya, Extra Trees cukup baik membaca pola tekstur permukaan, tetapi kurang tajam dalam memisahkan ripe dari dua kelas lain dibanding XGBoost.


Analisis Fitur Texture:

Pada fitur tekstur, ketiga model klasik masih mampu mengklasifikasikan buah sawit dengan akurasi tinggi, meskipun jumlah kesalahannya lebih besar dibanding fitur Normal maupun Warna. Pola didominasi oleh pergeseran kelas matang ke mentah atau busuk, yang menunjukkan bahwa informasi tekstur saja belum sepenuhnya cukup untuk membedakan fase kematangan yang berada di tengah. Di antara seluruh model, XGBoost dengan fitur tekstur menghasilkan confusion matrix paling bersih, sehingga dapat dianggap sebagai konfigurasi terbaik pada kelompok fitur tekstur.

10) XGBoost + Gabor

Analisis kinerja model XGBoost menggunakan fitur Gabor dilakukan melalui confusion matrix yang merepresentasikan

jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 20. Confusion Matrix XGBoost + Gabor

Hasil Analisis:

- Total sampel salah prediksi sebesar 24 sampel
- Pola error kesalahan pada mentah ke matang (6), matang ke mentah/busuk (8), dan busuk ke matang (7).
- Tidak ada kesalahan besar dalam busuk ke mentah.

11) SVM + Gabor

Analisis kinerja model SVM menggunakan fitur Gabor dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



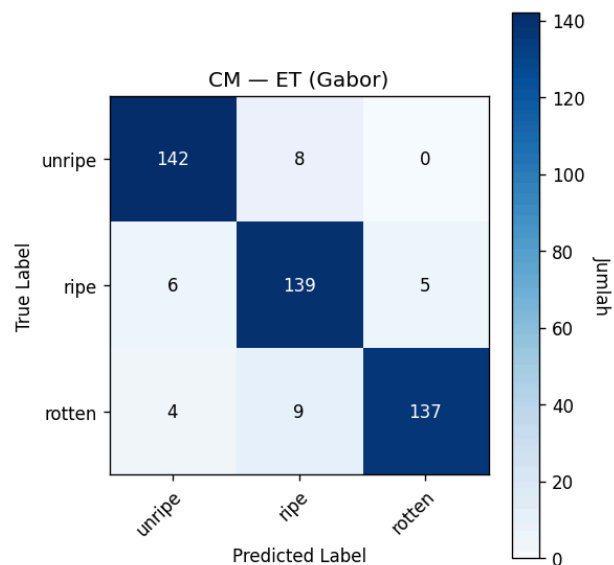
Gambar 21. Confusion Matrix SVM + Gabor

Hasil Analisis:

- Total sampel salah prediksi lumayan besar yaitu 35 sampel
- Error dominan terdapat pada busuk ke matang dan matang ke mentah.
- Ini menunjukkan SVM paling sensitif terhadap variasi pola Gabor, dan kesulitan membentuk boundary yang stabil antara ripe dan rotten.

12) ExtraTrees + Gabor

Analisis kinerja model ExtraTrees menggunakan fitur Gabor dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



Gambar 22. Confusion Matrix ExtraTrees + Gabor

Hasil Analisis:

- Total sampel salah prediksi lumayan besar yaitu 32 sampel
- Error dominan terdapat pada mentah ke matang dan busuk ke matang.

Analisis Fitur Gabor:

Pada fitur Gabor, performa ketiga model klasik masih berada pada kategori baik, namun secara umum lebih rendah dibanding fitur Warna dan Texture. Confusion matrix menunjukkan bahwa kesalahan klasifikasi didominasi oleh pergeseran antara kelas matang dan busuk, sedangkan kelas mentah relatif mudah dikenali. Di antara ketiga algoritma, XGBoost dengan fitur Gabor menghasilkan jumlah kesalahan paling sedikit, sehingga dapat dianggap sebagai model terbaik pada kelompok fitur Gabor, walaupun tetap belum dapat menyaingi kombinasi XGBoost dengan fitur Warna maupun Texture.

5. ANALYSIS ERROR

Pada metode klasik, tiga algoritma utama yang diuji adalah XGBoost, SVM, dan Extra Trees. Pada ekstraksi fitur (Normal, Color, Texture, Gabor). Secara umum, seluruh model klasik menghasilkan akurasi tinggi, yaitu di atas 0,90, dengan model terbaik XGBoost + Color yang mencapai akurasi 0,97.

Pola kesalahan ketiga model cukup konsisten yaitu kelas mentah dan busuk relatif mudah dikenali, sedangkan kelas matang menjadi sumber error utama karena sering tertukar ke mentah (buah yang masih hijau) atau busuk (buah yang sudah menghitam sebagian). Hal ini menunjukkan bahwa kasus-kasus borderline antar tingkat kematangan merupakan tantangan utama bagi seluruh model klasik, bukan hanya satu algoritma tertentu.


Error analysis (CM, LIME Tabular, LIME Image, MCW) ditampilkan untuk XGBoost + Gabor, XGBoost + Warna, dan XGBoost + Texture sebagai perwakilan metode klasik tiap fiturnya, karena performanya tinggi namun masih menyisakan error khas fitur tekstur (kelas matang sering bergeser ke mentah/busuk). Pola serupa juga muncul pada SVM dan Extra Trees, sehingga tidak semua model ditampilkan.

Berikut analysis error dari XGBoost dengan Gabor:

a. XGBoost + Gabor

1) Confusion Matrix

Analysis pertama dilihat menggunakan CM yang visualisasinya akan ditampilkan sebagai berikut:



Gambar 23. Confusion Matrix XGBoost + Gabor

Pada XGB + Gabor, akurasi keseluruhan yang dapat dilihat pada tabel 1. menunjukkan angka 0.94 - 0.95. Kesalahan dominan pada busuk yang diprediksi matang yaitu terdapat 7 sampel yang dapat dilihat pada gambar 23. Dengan fitur Gabor, model tetap kuat, tetapi lebih sering bingung di ripe dan rotten dibanding fitur Color/Normal, karena tekstur permukaan matang dan busuk kadang tidak berbeda drastis, apalagi jika busuk.

2) Most-Confident Wrong Samples

Analysis kedua dilihat menggunakan sampel citra yang diyakini prediksi salah, visualisasinya akan ditampilkan sebagai berikut:



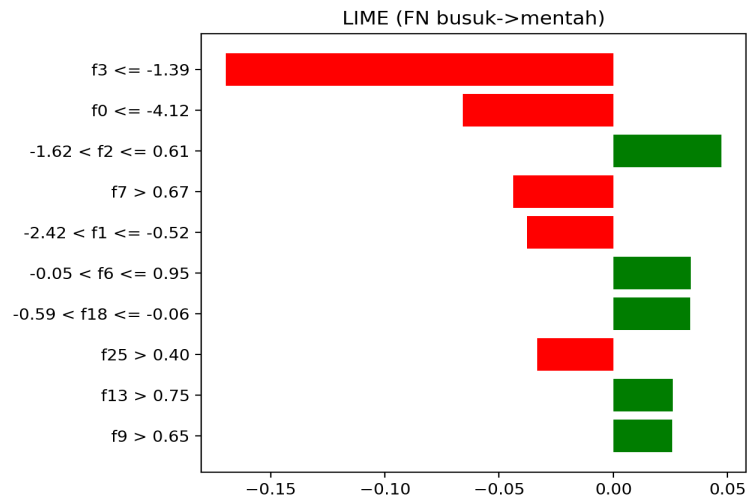
Gambar 24. Visualisasi Sampel Salah Prediksi

Pada gambar 24. diatas menunjukkan bahwa citra True adalah citra mentah yang diprediksi matang dengan confidence 0.81 dan 0.78. Kedua sampel

memiliki pola tekstur mirip sampel matang/busuk dibanding sampel mentah (yang cenderung lebih halus dan hijau kekuningan), sehingga model belajar bahwa kombinasi tekstur seperti ini adalah ciri kematangan.

3) LIME - Tabular

Analysis ketiga dilihat menggunakan LIME - Tabular yang visualisasinya akan ditampilkan sebagai berikut:

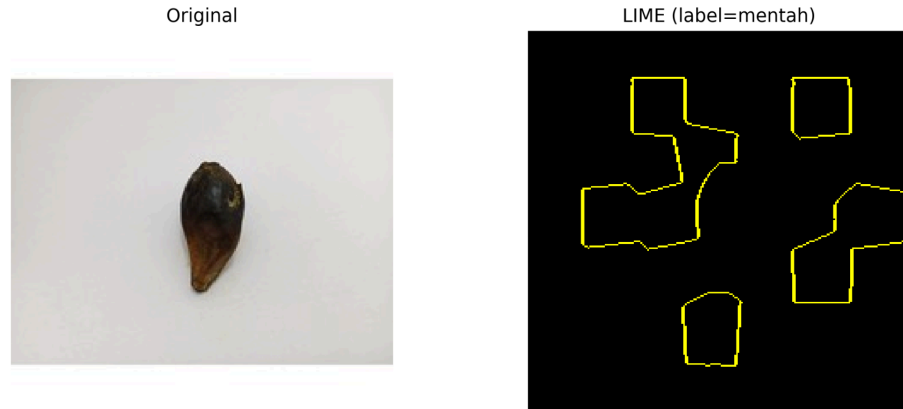


Gambar 25. Visualisasi LIME - Tabular

Gambar 25. di atas menunjukkan pada kelas busuk yang salah diprediksi mentah menggunakan Plot Lime Tabular. Plot LIME tersebut mempunyai komponen PCA dari HOG yaitu $f\#$ yang nilainya mencerminkan kombinasi histogram orientasi gradien. Komponen ($f2$, $f6$, $f18$, $f13$, $f9$) mendorong kuat ke kelas mentah (batang hijau), sementara fitur (merah) mengarah ke busuk namun total pengaruhnya kalah kuat. Artinya, pada sampel ini magnitudo respons Gabor di beberapa frekuensi–orientasi lebih mirip mentah (energi rendah/arrah sempit), sehingga proses boosting menumpuk aturan yang akhirnya memilih mentah.


4) LIME - Image

Analysis keempat dilihat menggunakan LIME - Image yang menampilkan kelas busuk dan visualisasinya akan ditampilkan sebagai berikut:



Gambar 26. Visualisasi LIME - Image Kelas Salah

Gambar 26. merupakan visualisasi dari kasus salah dimana objek busuk diprediksi sebagai mentah. Superpixel menjelaskan bahwa prediksi mentah banyak jatuh pada latar putih dan tepi global di sekitar objek. Karena Gabor peka arah/frekuensi, respons pada latar yang halus dan sedikit blur menjadi lemah, membentuk pola magnitudo yang mirip mentah sehingga mendorong keputusan keliru. Kontribusi dari area buah justru minim tanda bahwa model tertarik pada konteks, bukan tekstur buahnya.



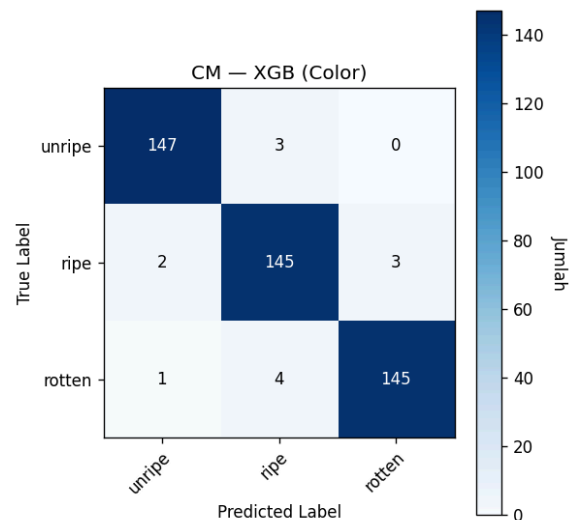
Gambar 27. Visualisasi LIME - Image Kelas Benar

Gambar 27. merupakan visualisasi dari kasus benar yaitu kelas busuk. Superpixel penjelas berada di permukaan buah (kontur dan bercak), menonjolkan pola berarah/berbintik busuk. Di sini, bank Gabor menangkap energi pada orientasi/frekuensi tertentu sehingga skor kelas busuk naik.

b. XGBoost + Warna

1) Confusion Matrix

Analysis pertama dilihat menggunakan CM yang visualisasinya akan ditampilkan sebagai berikut:



Gambar 28. Confusion Matrix XGBoost + Warna

Pada Random XGBoost + Warna, akurasi keseluruhan yang dapat dilihat pada tabel 1. menunjukkan angka 0.97. Pada gambar 28. terdapat sedikit kesalahan yang dominan pada matang yang diprediksi mentah ataupun busuk.

2) Most-Confident Wrong Samples

Analysis kedua dilihat menggunakan sampel citra yang diyakini prediksi salah, visualisasinya akan ditampilkan sebagai berikut:

Pred: mentah (0.89)
True: busuk



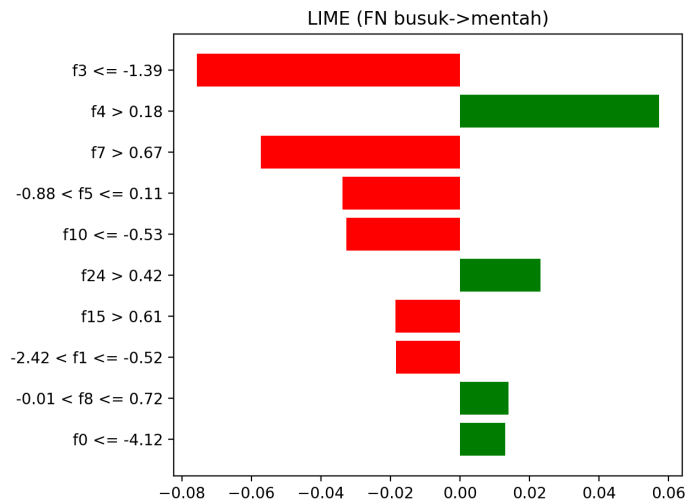
Gambar 29. Visualisasi Sampel Salah Prediksi

Pada gambar 29. diatas menunjukkan bahwa citra True adalah citra busuk yang diprediksi mentah dengan confidence 0.89. Sampel tersebut memiliki latar putih terang dan area gelap yang kadang ikut menjadi coklat

muda/kuning gelap, sehingga tidak tertangkap sebagai warna rotten yang khas (cokelat sangat gelap/hitam).

3) LIME - Tabular

Analysis ketiga dilihat menggunakan LIME - Tabular yang visualisasinya akan ditampilkan sebagai berikut:

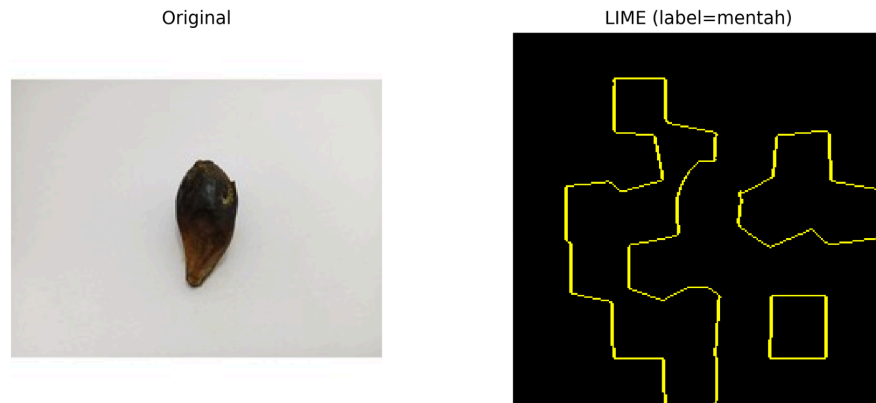


Gambar 30. Visualisasi LIME - Tabular

Gambar 30. di atas menunjukkan bahwa kelas busuk salah diprediksi mentah menggunakan Plot Lime Tabular. Komponen ($f4 > 0.18$, $f24 > 0.42$, $f15 > 0.61$, $f8$ dan $f0$) mendorong kuat ke kelas mentah (batang hijau), sementara fitur (merah) mengarah ke busuk namun total pengaruhnya lebih kecil sehingga voting XGBoost jatuh ke mentah. Fitur yang mestinya mewakili (merah) kontribusinya jadi kecil karena luas area busuk sedikit atau intensitasnya nggak terlalu gelap. Sebaliknya, fitur yang mewakili hijau punya kontribusi positif kuat ke kelas mentah.

4) LIME - Image

Analysis keempat menggunakan LIME - Image yang visualisasinya akan ditampilkan sebagai berikut:



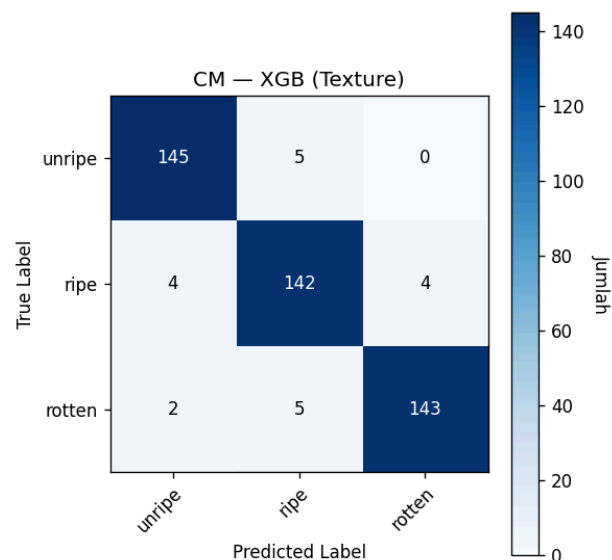
Gambar 31. Visualisasi LIME - Image Kelas Salah

Gambar 31. merupakan visualisasi dari kasus salah dimana objek busuk diprediksi sebagai mentah. Superpixel banyak jatuh pada latar putih dan tepi global di sekitar objek. Sementara area busuk yang kecil tidak terlalu disorot karena tidak dominan secara luas.

c. XGBoost Texture

1) Confusion Matrix

Analysis pertama dilihat menggunakan CM dan F1 per kelas yang visualisasinya akan ditampilkan sebagai berikut:




Gambar 32. Confusion Matrix Normalisasi

Pada XGBoost + Texture, akurasi keseluruhan yang dapat dilihat pada tabel 1. menunjukkan angka 96%. Pada gambar 32. terdapat sedikit kesalahan yang

dominan pada matang diprediksi mentah ataupun busuk dengan total yaitu 8 sampel (total keseluruhan salah prediksi yaitu 20).

2) Most-Confident Wrong Samples

Analysis kedua dilihat menggunakan sampel citra yang diyakini prediksi salah, visualisasinya akan ditampilkan sebagai berikut:

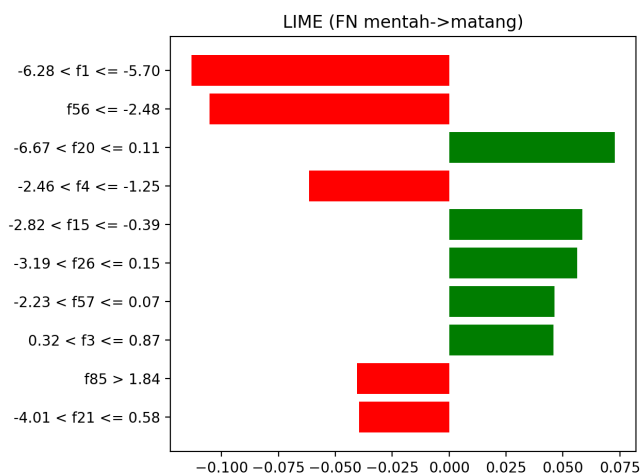


Gambar 33. Visualisasi Sampel Salah Prediksi

Pada gambar 33. diatas menunjukkan bahwa citra True adalah mentah yang salah diprediksi matang dengan confidence 0,66, 0.48, dan 0,47. Pola buah mentah yaitu permukaan cenderung lebih halus dan pola teksturnya sederhana. Kesalahan prediksi terjadi karena buah mentah sudah terlihat memiliki permukaan yang sedikit kasar atau memiliki bercak-bercak.

3) LIME - Tabular

Analysis ketiga dilihat menggunakan LIME - Tabular yang visualisasinya akan ditampilkan sebagai berikut:

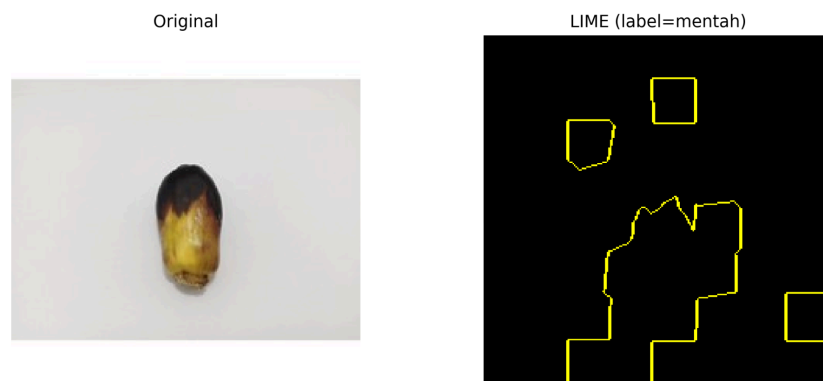


Gambar 34. Visualisasi LIME - Tabular

Gambar 34. di atas menunjukkan bahwa kelas mentah salah diprediksi matang menggunakan Plot Lime Tabular. Komponen (f20, f26, f57, f3, f21) memberi kontribusi positif dan mendorong kuat ke kelas matang (batang hijau), sementara komponen lain (f1, f56, f4, f15, f85) justru mengarah ke mentah (batang merah) namun total kontribusinya lebih kecil. Pada sampel ini, fitur seperti contrast, entropy, energy, biasanya menghasilkan pola orientasi yang mirip matang, sehingga boosting XGBoost menumpuk aturan yang akhirnya memberi skor lebih tinggi ke matang.

4) LIME - Image

Analysis keempat dilihat menggunakan LIME - Image yang visualisasinya akan ditampilkan sebagai berikut:



Gambar 35. Visualisasi LIME - Image Kelas Salah

Gambar 35. merupakan visualisasi dari kasus salah dimana objek mentah diprediksi sebagai matang. Superpixel fokus pada area dengan tekstur paling rame, sehingga model melihat pola kasar seperti pada contoh matang di atas.



Gambar 36. Visualisasi LIME - Image Kelas Benar

Gambar 36. merupakan visualisasi dari kasus benar kelas mentah. Superpixel penjas terkonsentrasi di objek terutama bagian kulit yang paling banyak garis/bintik/kerutan.

6. Deep Learning - CNN with Transformer

Pendekatan Deep Learning berikut memanfaatkan model Convolutional Neural Network (CNN) yang dilatih dari nol (from scratch) dan model berbasis Vision Transformer (MaxViT-Tiny dan ViT-B/16).

6.1 Arsitektur CNN Scratch

Arsitektur CNN scratch menggunakan beberapa blok konvolusi dan pooling untuk mengekstraksi fitur spasial, kemudian diikuti oleh lapisan fully connected untuk klasifikasi. Secara umum, struktur model dapat diringkas sebagai berikut:

A. Input layer

- 1) Citra RGB buah sawit dengan ukuran $224 \times 224 \times 3$ (atau ukuran lain yang digunakan pada eksperimen).

B. Blok fitur (feature extraction)

- 1) Beberapa lapisan Conv2D dengan kernel kecil dan aktivasi ReLU.
- 2) Setiap 1–2 lapisan konvolusi diikuti oleh MaxPooling2D untuk mereduksi ukuran spasial dan menahan fitur yang paling penting.
- 3) Batch normalization dan dropout untuk menstabilkan training dan mengurangi overfitting.

C. Blok klasifikasi (classifier head)

- 1) Lapisan Flatten atau GlobalAveragePooling2D untuk mengubah peta fitur menjadi vektor.
- 2) Satu atau dua lapisan Dense dengan aktivasi ReLU.
- 3) Lapisan Dropout untuk regularisasi.
- 4) Lapisan output Dense dengan 3 neuron dan aktivasi softmax untuk memprediksi tiga kelas: mentah, matang, dan busuk.

6.2 CNN dengan ViT-B/16

Arsitektur ViT-B/16 diambil dari TensorFlow Hub / pustaka resmi dengan bobot prelatih pada dataset skala besar. Tahapan pemrosesan utamanya adalah

A. Patch embedding

- 1) Citra 224×224 dibagi menjadi patch 16×16 piksel.
- 2) Setiap patch di-flatten lalu diproyeksikan ke vektor embedding berdimensi tetap sehingga membentuk deretan token visual.

B. Penambahan positional encoding

- 1) Informasi posisi patch ditambahkan pada tiap token untuk mempertahankan struktur spasial citra.

C. Encoder transformer

- 1) Deretan token dilewatkan ke beberapa blok encoder yang berisi Multi-Head Self-Attention (MHSA) dan feed-forward network, lengkap dengan residual connection dan layer normalization, sehingga model dapat menangkap dependensi global antar patch.

D. Head klasifikasi baru

- 1) Representasi token klasifikasi ([CLS] atau rata-rata token) diteruskan ke head baru:
Dense - Dropout - Dense (3, softmax) untuk memprediksi kelas mentah, matang, dan busuk.

Pada tahap fine-tuning, sebagian besar backbone ViT-B/16 dibiarkan trainable dengan learning rate kecil agar pengetahuan umum dari pretrained model dapat disesuaikan dengan domain citra sawit.

6.3 CNN dengan MaxViT-Tiny

MaxViT (Multi-Axis Vision Transformer) merupakan arsitektur hybrid yang menggabungkan konvolusi dengan attention lokal dan global. Alurnya berikut:

- A. Convolutional stem di awal jaringan untuk mengekstraksi fitur lokal tingkat rendah (tepi, tekstur halus).
- B. Beberapa stage hierarkis yang masing-masing berisi:
 - 1) Window attention (self-attention dalam jendela lokal kecil),
 - 2) Grid attention (self-attention pada patch yang tersebar secara global),
 - 3) disertai operasi downsampling untuk membentuk representasi multi-skala mirip CNN.

Seperti ViT-B/16, MaxViT juga digunakan sebagai backbone pretrained (Keras/TF Hub). Lapisan klasifikasi aslinya dihapus dan diganti dengan head tiga kelas (mentah, matang, busuk) yang dilatih ulang pada data sawit.

6.4 Teknik dalam Eksperimen

A. Freeze (baseline)

- 1) Seluruh lapisan encoder dibekukan (frozen) sehingga bobot backbone tidak diperbarui selama training.
- 2) Hanya head klasifikasi baru yang dilatih pada dataset sawit.
- 3) Skenario ini menjadi baseline transfer learning paling murah, karena jumlah parameter yang dilatih paling sedikit.

B. Fine-tuning normal (FT2)

- 1) Dua blok terakhir encoder dibuka (unfreeze) sehingga ikut dilatih bersama head.
- 2) Digunakan data augmentation ringan (weak augmentation), seperti rotasi kecil, flip horizontal, dan sedikit zoom.
- 3) Fungsi loss: categorical cross-entropy (CE).
- 4) Skenario ini merepresentasikan fine-tuning konvensional: lebih banyak parameter diubah sehingga model lebih spesifik terhadap domain sawit.

C. LoRA pada lapisan atas

- 1) Diterapkan teknik Low-Rank Adaptation (LoRA) pada lapisan atas.
- 2) Konfigurasi: rank = 8 dan alpha = 16, dengan weak augmentation dan loss CE yang sama seperti FT2.
- 3) LoRA menambahkan matriks ber-rank rendah pada lapisan tertentu sehingga hanya sedikit parameter tambahan yang dilatih, sementara bobot asli backbone tetap sebagian besar dipertahankan.
- 4) Tujuannya adalah memperoleh kinerja mendekati fine-tuning penuh, tetapi dengan biaya komputasi dan memori yang lebih hemat.

6.5 Evaluasi

A. Classification Report

Classification Report berupa ringkasan metrik performa model klasifikasi. Laporan ini menunjukkan bagaimana performa model dalam memprediksi tiap kelas, menggunakan metrik dengan classification report berikut:

Tabel 2. Hasil Evaluasi Deep Learning CNN

Model	Kelas	Acc	Precision	Recall	F1-Score
-------	-------	-----	-----------	--------	----------

CNN - Scratch	Mentah	0.87	0.86	0.92	0.89
	Matang		0.83	0.86	0.85
	Busuk		0.92	0.84	0.88
ViT-B/16 Freeze	Mentah	0.96	0.96	0.98	0.97
	Matang		0.95	0.95	0.95
	Busuk		0.97	0.96	0.96
ViT-B/16 FT2	Mentah	0.98	0.96	0.99	0.98
	Matang		0.97	0.97	0.97
	Busuk		0.99	0.97	0.98
ViT-B/16 LoRA	Mentah	0.98	0.98	0.99	0.98
	Matang		0.98	0.98	0.98
	Busuk		0.99	0.98	0.98
MaxViT-T Freeze	Mentah	0.96	0.97	0.98	0.97
	Matang		0.95	0.96	0.95
	Busuk		0.97	0.96	0.97
MaxViT-T FT2	Mentah	0.98	0.98	0.99	0.98
	Matang		0.97	0.97	0.97
	Busuk		0.98	0.98	0.98
MaxViT-T LoRA	Mentah	0.98	0.99	0.98	0.99
	Matang		0.97	0.98	0.98
	Busuk		0.99	0.98	0.99

Analisis:

Berdasarkan classification report di atas, menunjukkan bahwa:


- 1) Pada CNN scratch hanya mencapai akurasi sekitar 0,87 dengan F1-score per kelas di kisaran 0,85–0,89. Kinerja terendah terjadi pada kelas matang, yang sering tertukar dengan kelas mentah maupun busuk.

- 2) Sebaliknya, seluruh model berbasis transformer menunjukkan peningkatan performa yang sangat signifikan. Baik ViT-B/16 maupun MaxViT-T pada skenario frozen sudah mampu mencapai akurasi sekitar 0,96 dengan nilai precision, recall, dan F1-score di atas 0,95. Ketika backbone di-fine-tune (FT) atau disesuaikan menggunakan LoRA, akurasi meningkat menjadi sekitar 0,98 dengan F1-score per kelas berada pada rentang 0,97–0,99 dan distribusi performa antar kelas menjadi jauh lebih seimbang.
- 3) Hasil analisis ini menegaskan bahwa deep learning dengan arsitektur transformer modern jauh lebih efektif dibanding melatih CNN dari nol pada dataset yang terbatas. Selain itu, teknik LoRA mampu memberikan kinerja yang setara bahkan sedikit lebih stabil dibanding full fine-tuning, dengan biaya komputasi yang lebih rendah sehingga menjadi pilihan yang menarik untuk implementasi praktis.

B. Confusion Matrix

1) CNN - Scratch

Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:




Gambar 37. Confusion Matrix CNN scratch

Hasil Analisis:

Confusion matrix pada CNN yang dilatih dari nol menunjukkan bahwa akurasi model masih berada pada kisaran 87–88% dengan pola mis-klasifikasi yang didominasi oleh pergeseran antara kelas matang dan busuk. Kelas mentah relatif mudah dikenali ($\text{recall} \pm 0,92$), sedangkan kelas matang dan busuk lebih sering tertukar karena kemiripan pola warna dan tekstur pada buah yang hampir matang ataupun busuk sebagian. Hal ini mengindikasikan bahwa CNN yang dilatih dari nol belum mampu mengekstraksi fitur, sehingga performanya masih berada di bawah model klasik.

2) CNN ViT-B/16 Freeze

Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:




Gambar 38. Confusion Matrix CNN ViT-B/16 Freeze

Hasil Analisis:

- 1) Kelas mentah sudah hampir sempurna, hanya 3 buah yang salah prediksi ke matang.
- 2) Kelas matang salah prediksi terbagi ke unripe dan rotten.
- 3) Busuk kadang diprediksi sebagai matang (4) atau unripe (2).
- 4) Backbone umum, sehingga model belum sepenuhnya menangkap nuansa warna/tekstur kematangan sawit.

3) CNN ViT-B/16 FT2

Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:




Gambar 39. Confusion Matrix CNN ViT-B/16 FT2

Hasil Analisis:

- 1) Kesalahan kelas matang turun dari 7 ke 4 kasus.
- 2) Kesalahan kelas rotten turun dari 6 ke 4 kasus.
- 3) Pola errornya masih sama yaitu kesalahan pada kelas matang ke mentah ataupun busuk, hanya frekuensinya menurun.

4) CNN ViT-B/16 LoRA


Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:



Gambar 40. Confusion Matrix CNN ViT-B/16 LoRA

Hasil Analisis:


- 1) Total salah hanya 7 sampel yaitu, 3 di matang (2 ke mentah dan 1 ke busuk), 3 di busuk(1 ke mentah dan 2 ke matang), 1 di mentah ke matang.
 - 2) Tidak ada eror yang sangat signifikan.
 - 3) Dengan LoRA, model hanya meng-update matriks kecil pada lapisan attention, tetapi sudah cukup untuk menyesuaikan orientasi ruang fitur ke domain sawit tanpa merusak pengetahuan global yang dibawa dari pretraining.
- 5) CNN MaxViT-T Freeze
- Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:



Gambar 41. Confusion Matrix CNN MaxViT-T Freeze

Hasil Analisis:


- 1) Mentah sudah sangat baik, hanya 3 sampel yang salah prediksi ke matang.
 - 2) Matang dan busuk beberapa kali tertukar satu sama lain
 - 3) Transformer ini mirip ViT-B/16 Frozen yaitu, backbone masih ImageNet, sehingga belum sepenuhnya menangkap karakteristik khusus sawit.
- 6) CNN MaxViT-T FT2
- Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:



Gambar 42. Confusion Matrix CNN MaxViT-T FT2

Hasil Analisis:

- 1) Kesalahan prediksi terdapat 8 sampel.
 - 2) Kesalahan tinggal beberapa kasus matang ke mentah atau busuk dan busuk ke matang.
 - 3) Setelah seluruh backbone MaxViT-T ikut di-update, model menjadi jauh lebih peka terhadap pola warna + tekstur spesifik.
- 7) CNN MaxViT-T LoRA
- Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, yang ditampilkan berikut ini:



Gambar 43. Confusion Matrix CNN MaxViT-T LoRA

Hasil Analisis:

- 1) Kesalahan prediksi sangat kecil yaitu 6 sampel yaitu 2 mentah diprediksi matang, 2 matang diprediksi busuk dan mentah, dan 2 busuk di prediksi matang.
- 2) Dengan hanya meng-update matriks LoRA di layer attention, MaxViT-T LoRA mampu menyesuaikan diri dengan domain sawit tanpa merombak besar-besaran backbone, sehingga stabil tapi tetap sangat akurat.

7. Transfer Learning dengan Fine-Tuning dan LoRA

Pendekatan Deep Learning berikut memanfaatkan model Convolutional Neural Network (CNN) dengan fine-tuning. CNN dipilih karena mampu mengenali pola pada data gambar. Penggunaan CNN dengan fine-tuning dilakukan agar dapat meningkatkan kinerja model. Pada proyek ini digunakan dua arsitektur CNN, yaitu EfficientNet-B0 dan ResNet-50. Arsitektur tersebut merupakan model deep learning yang sudah dipra-latih (pre-trained) pada dataset ImageNet dan kemudian disesuaikan kembali menggunakan pendekatan transfer learning.

7.1 Model

A. EfficientNet-B0

EfficientNet-B0 merupakan arsitektur CNN yang menggabungkan depth, width, dan resolution scaling secara seimbang sehingga mampu mencapai

performa tinggi dengan jumlah parameter relatif lebih kecil dibanding model lain.

A. ResNet-50

ResNet-50 merupakan arsitektur Residual Network dengan 50 lapisan, yang dirancang untuk mengatasi masalah degradasi performa pada CNN melalui penggunaan residual connection (shortcut).

7.2 Struktur Umum Model:

A. Backbone pralatih

- 1) EfficientNet-B0 tanpa lapisan klasifikasi asli.
- 2) Bobot awal: pretrained ImageNet.
- 3) Input citra: $224 \times 224 \times 3$.

B. Head klasifikasi baru

- 1) Lapisan GlobalAveragePooling2D.
- 2) Satu lapisan Dense dengan aktivasi ReLU.
- 3) Lapisan Dropout untuk mengurangi overfitting.
- 4) Lapisan output Dense dengan 3 neuron dan aktivasi softmax.

7.3 Teknik dalam Eksperimen

Teknik dalam bereksperimen tidak jauh beda dengan teknik eksperimen dalam CNN scratch sebelumnya. Terdapat 3 teknik yaitu freeze, fine tuning, dan LoRA.

7.4 Evaluasi

1) Classification Report

Classification Report berupa ringkasan metrik performa untuk model klasifikasi. Laporan ini menunjukkan bagaimana performa kedua model dalam memprediksi tiap kelas, menggunakan metrik-metrik utama dengan classification report berikut:

Tabel 3. Hasil Evaluasi Transfer Learning

Teknik	Kelas	Acc	Precision	Recall	F1-Score
EffecientNet-B0					
Freeze	Mentah	0.96	0.96	0.97	0.96

	Matang		0.94	0.95	0.95
	Busuk		0.97	0.95	0.96
FT2	Mentah	0.97	0.98	0.98	0.98
	Matang		0.96	0.97	0.96
	Busuk		0.98	0.97	0.97
LoRA	Mentah	0.97	0.98	0.98	0.98
	Matang		0.96	0.97	0.97
	Busuk		0.98	0.97	0.97
ResNet-50					
Freeze	Mentah	0.95	0.95	0.98	0.96
	Matang		0.94	0.95	0.95
	Busuk		0.98	0.95	0.96
FT2	Mentah	0.97	0.96	0.98	0.97
	Matang		0.96	0.96	0.96
	Busuk		0.98	0.96	0.97
LoRA	Mentah	0.96	0.95	0.98	0.96
	Matang		0.94	0.95	0.95
	Busuk		0.98	0.95	0.96

Analisis:


Berdasarkan hasil classification report diatas, secara keseluruhan EfficientNet-B0 maupun ResNet-50 menunjukkan performa yang sangat tinggi dengan nilai akurasi, precision, recall, dan F1-score di atas 0,95 pada seluruh konfigurasi. EfficientNet-B0 cenderung sedikit lebih stabil terutama pada skenario Freeze dan LoRA, sedangkan ResNet-50 memperoleh performa terbaik pada skenario fine-tuning penuh (FT2). Hal ini mengindikasikan bahwa kedua backbone CNN modern ini sama-sama layak digunakan untuk klasifikasi kematangan buah sawit, dengan pilihan konfigurasi dapat disesuaikan pada kebutuhan efisiensi komputasi (LoRA) atau pencapaian akurasi maksimum (FT2).

2) Confusion Matrix

Confusion Matrix berupa tabel matrix yang merinci jumlah prediksi benar dan salah yang dibuat oleh model, dibandingkan dengan label sebenarnya.

a. EffecientNet-B0 Freeze

Analisis kinerja model EffecientNet-B0 menggunakan teknik Freeze dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 44. Confusion Matrix EffecientNet-B0 Freeze

Hasil Analisis:

- 1) Kelas mentah sudah cukup bagus, tapi masih ada 4 buah yang bergeser ke matang ataupun busuk.
- 2) Kelas matang dan busuk beberapa kali tertukar (3 dan 5 kasus salah prediksi).
- 3) Model mengandalkan fitur generik ImageNet karena freeze, jadi pemisahan halus antara matang ke busuk belum optimal.

b. EffecientNet-B0 FT2

Analisis kinerja model EffecientNet-B0 menggunakan teknik FT2 dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 45. Confusion Matrix EffecientNet-B0 FT2

Hasil Analisis:

- 1) Kesalahan prediksi turun dari sebelumnya yaitu terdapat 11 sampel.
- 2) Tidak ada lagi salah prediksi mentah ke busuk.
- 3) Matang dan busuk masih kadang tertukar satu sama lain, tapi frekuensinya mengecil.

c. EffecientNet-B0 LoRA

Analisis kinerja model EffecientNet-B0 menggunakan teknik LoRA dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 46. Confusion Matrix EffecientNet-B0 LoRA

Hasil Analisis:

- 1) Terdapat kesalahan pada mentah ke matang (2), matang ke mentah atau busuk (4), dan busuk ke mentah atau matang (4).
- 2) Kesalahan klasifikasi terjadi antar kelas yang memang bertetangga.
- 3) Meng-update parameter LoRA pada beberapa layer, model sedikit lebih baik dari full fine-tuning dan lebih hemat komputasi.

d. ResNet-50 Freeze

Analisis kinerja model ResNet-50 menggunakan teknik Freeze dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 47. Confusion Matrix ResNet-50 Freeze

Hasil Analisis:

- 1) Mentah sudah cukup baik (3 salah).
- 2) Matang dan busuk beberapa kali tertukar (5 & 5 kasus).
- 3) Backbone masih murni ImageNet, jadi pemisahan halus ripe–rotten belum maksimal.

e. ResNet-50 FT2

Analisis kinerja model ResNet-50 menggunakan teknik FT2 dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:




Gambar 48. Confusion Matrix ResNet-50 FT2

Hasil Analisis:

- 1) Terdapat kesalahan prediksi sebanyak 12 sampel.
- 2) Artinya setelah seluruh backbone di-update, feature ResNet-50 jadi lebih spesifik ke pola warna/tekstur sawit.

f. ResNet-50 LoRA

Analisis kinerja model ResNet-50 menggunakan teknik LoRA dilakukan melalui confusion matrix yang merepresentasikan jumlah prediksi benar dan salah, sebagaimana ditampilkan berikut ini:



Gambar 49. Confusion Matrix ResNet-50 LoRA

Hasil Analisis:

- 1) Semua kesalahan prediksi terjadi antar kelas yang memang berdekatan secara kematangan.
- 2) Dengan hanya meng-update matriks LoRA di beberapa layer, ResNet-50 LoRA sedikit lebih baik dari full fine-tuning dan lebih hemat parameter.

8. Perbandingan Hasil Metode

Perbandingan hasil uji dataset telah dilakukan dengan menggunakan berbagai metode. Berikut hasil perbandingannya:

Tabel 4. Hasil Perbandingan Uji Klasifikasi Buah Sawit

Metode	Model	Akurasi	Kekuatan	Catatan
Klasik + Ekstraksi Fitur	Kombinasi fitur warna, tekstur, Gabor + XGB / SVM/ ET	0,92 – 0,98	Akurat, komputasi relatif ringan, fitur mudah diinterpretasi	Masih banyak terdapat error pada kelas matang dan busuk.
CNN Scratch	CNN Conv–Pool–Dense (train from scratch)	0,87	Arsitektur sederhana; tidak bergantung pretraining.	Performa paling rendah, kelas matang sulit dideteksi, butuh data lebih besar & tuning berat.
Transformer (ViT-B/16)	Freeze, FT2, LoRA	0.96-0.98	ViT-B/16 Freeze sudah mencapai akurasi tinggi 0,96, LoRA mendorong akurasi 0,98, sedangkan FT2 menjadi konfigurasi paling optimal karena mampu memaksimalkan pemahaman konteks global citra.	ViT-B/16 Freeze sudah kuat sebagai baseline, FT2 optimal tapi berat secara komputasi, sedangkan LoRA memberi kompromi terbaik karena mendekati performa FT2 dengan update parameter.
Transformer MaxViT-T	Freeze, FT2, LoRA	0.96-0.98	Pada arsitektur Freeze sudah kuat karena dapat menangkap pola lokal dan global, FT2 mengoptimalkan pemahaman detail	Freeze/FT2 sedikit di bawah LoRA.

			warna dan tekstur sawit, performa LoRA setara FT2 dengan parameter yang di-update jauh lebih sedikit.	
Transfer Learning – EfficientNet-B0	Freeze, FT2, LoRA	0.96-0.97	Arsitektur pada model relatif ringan. Pada Freeze, model cukup kuat. Pada FT2, performa meningkat dengan F1 yang lebih seimbang antar kelas, sedangkan LoRA mempertahankan akurasi setara FT2.	Freeze terdapat selisih performa di kelas matang yang kadang tertukar dengan mentah atau busuk. Konfigurasi FT2 membutuhkan waktu training dan sumber komputasi lebih besar dibanding LoRA.
Transfer Learning – ResNet-50	Freeze, FT2, LoRA	0.95-0.97	Mode Freeze sudah kuat karena mampu menangkap pola lokal dan global tanpa banyak penyesuaian. Pada FT2, performa semakin optimal. Sementara LoRA memberikan kinerja setara FT2.	Freeze sudah bagus, tetapi masih terdapat beberapa kasus borderline salah prediksi. Konfigurasi FT2 menuntut sumber daya komputasi dan waktu training paling besar karena banyak parameter yang di-update. Sedangkan LoRA lebih hemat komputasi,

Berdasarkan Tabel di atas, pendekatan terbaik untuk klasifikasi kematangan sawit pada dataset ini sebagai berikut:

1) Metode Klasik: XGBoost + Color

- a. Performa tertinggi di metode klasik di antara semua kombinasi klasik (XGBoost, SVM, Extra Trees × Normal/Color/Texture/Gabor), XGBoost + Color konsisten punya akurasi dan F1 tertinggi dengan jumlah error paling sedikit.
- b. Confusion matrix, sebagian besar sampel tepat hanya sedikit kesalahan di kelas matang dan busuk.

- c. Fitur warna sangat relevan secara domain, fitur ini lebih mudah dijelaskan ke orang lapangan untuk menentukan kematangan buah melalui warna.

2) CNN Transformer: MaxViT-T + LoRA

- a. Performa tertinggi di metode CNN dengan transformer yaitu akurasi 0.98 dengan recall dan F1 yang sangat seimbang di semua kelas.
- b. Kombinasi CNN + MaxViT-T cocok untuk citra sawit yang butuh warna dan tekstur sekaligus.
- c. LoRA = kinerja tinggi tetapi efisien dan parameter lebih hemat.

3) Transfer Learning: EfficientNet-B0 + LoRA

- a. Performa sangat tinggi dan stabil mencapai akurasi 0.97 dengan precision–recall yang seimbang di tiap kelas.
- b. Jauh lebih baik dibanding CNN scratch, dan selevel dengan ResNet-50 FT2 tapi dengan biaya lebih ringan.
- c. Teknik LoRA sangat efisien untuk praktik nyata karena model tidak perlu fine-tuning penuh, hanya sebagian kecil parameter yang di-update.